Practica1

Nicolás Camacho

2026-10-20

1. Introducción

```
# Creamos la carpeta para los datos si no existe
if (!file.exists('data')){
  dir.create('data')
}

# Creamos la carpeta para la figura
if (!file.exists('figure')){
  dir.create('figure')
}
```

2. Ejemplo: fichero *DFP1_11122015 124700.csv*

2.1. Importación del fichero

```
library(readr)
fname <- 'data/DFP1_11122015 124700.csv'

dfp1 <- read_delim(fname, delim = "\t") # Con readr
```

```
## Rows: 8887 Columns: 5
## -- Column specification --------------------------------------------------------
## Delimiter: "\t"
## chr  (1): FECHA
## dbl  (3): Altura, Combinacion_Canya, Temperatura
## time (1): HORA
##
## i Use `spec()` to retrieve the full column specification for this data.
## i Specify the column types or set `show_col_types = FALSE` to quiet this message.
```

```
dfp1.base <- read.csv(fname, sep = "\t") # Con base
```

```
head(dfp1)
```

```
## # A tibble: 6 x 5
##   FECHA      HORA     Altura Combinacion_Canya Temperatura
```

```
##   <chr>      <time>    <dbl>             <dbl>       <dbl>
## 1 11/12/2015 12:47:02   138.                 2        14.6
## 2 11/12/2015 12:47:02   138.                 2        14.6
## 3 11/12/2015 12:47:02   138.                 2        14.6
## 4 11/12/2015 12:47:03   138.                 2        14.6
## 5 11/12/2015 12:47:03   138.                 2        14.6
## 6 11/12/2015 12:47:03   138.                 2        14.6
```

```
head(dfp1.base)
```

```
##        FECHA     HORA Altura Combinacion_Canya Temperatura
## 1 11/12/2015 12:47:02 137.81                 2        14.6
## 2 11/12/2015 12:47:02 137.81                 2        14.6
## 3 11/12/2015 12:47:02 137.81                 2        14.6
## 4 11/12/2015 12:47:03 137.81                 2        14.6
## 5 11/12/2015 12:47:03 137.81                 2        14.6
## 6 11/12/2015 12:47:03 137.81                 2        14.6
```

Aplicando la tabulación como separador entre las variables, se observa que ambas importaciones son equivalentes. Nos quedaremos con la proporcionada por readr, ya que la hora ya está en formato hms.

```
install.packages("hms", repos = "https://cloud.r-project.org")
```

```
## Installing package into 'C:/Users/Nico/AppData/Local/R/win-library/4.6'
## (as 'lib' is unspecified)
```

```
## package 'hms' successfully unpacked and MD5 sums checked
##
## The downloaded binary packages are in
##  C:\Users\Nico\AppData\Local\Temp\RtmpoNor3s\downloaded_packages
```

```
library(hms)
```

La hora con la importación de readr ya viene en hms, por lo que aplicamos el cambio solo a la importación con base y posteriormente comprobamos que se ha hecho bien la conversión:

```
hora <- as_hms(dfp1.base$HORA)
head(hora)
```

```
## 12:47:02
## 12:47:02
## 12:47:02
## 12:47:03
## 12:47:03
## 12:47:03
```

```
str(hora)
```

```
##  'hms' num [1:8887] 12:47:02 12:47:02 12:47:02 12:47:03 ...
##  - attr(*, "units")= chr "secs"
```

Ahora cambiamos la fecha a formato POSIX para el dataframe con el que trabajamos y comprobamos que la conversión está bien hecha:

```
dfp1$FECHA <- as.POSIXlt(dfp1$FECHA, format = '%d/%m/%Y')
head(dfp1$FECHA)
```

```
## [1] "2015-12-11 CET" "2015-12-11 CET" "2015-12-11 CET" "2015-12-11 CET"
## [5] "2015-12-11 CET" "2015-12-11 CET"
```

```
str(dfp1$FECHA)
```

```
##  POSIXlt[1:8887], format: "2015-12-11" "2015-12-11" "2015-12-11" "2015-12-11" "2015-12-11" ...
```

Lo almacenamos en la carpeta results dentro de data:

```
if (!file.exists('data/results')){
  dir.create('data/results')
}
save(dfp1, file = 'data/results/dfp1.RData')
```

2.2. Inspección de los datos

```
str(dfp1)
```

```
## spc_tbl_ [8,887 x 5] (S3: spec_tbl_df/tbl_df/tbl/data.frame)
##  $ FECHA            : POSIXlt[1:8887], format: "2015-12-11" "2015-12-11" ...
##  $ HORA             : 'hms' num [1:8887] 12:47:02 12:47:02 12:47:02 12:47:03 ...
##   ..- attr(*, "units")= chr "secs"
##  $ Altura           : num [1:8887] 138 138 138 138 138 ...
##  $ Combinacion_Canya: num [1:8887] 2 2 2 2 2 2 2 2 2 2 ...
##  $ Temperatura      : num [1:8887] 14.6 14.6 14.6 14.6 14.6 14.6 14.6 14.6 14.6 14.6 ...
##  - attr(*, "spec")=
##   .. cols(
##   ..   FECHA = col_character(),
##   ..   HORA = col_time(format = ""),
##   ..   Altura = col_double(),
##   ..   Combinacion_Canya = col_double(),
##   ..   Temperatura = col_double()
##   .. )
##  - attr(*, "problems")=<pointer: 0x0000021ab48fedc0>
```

Vemos que tenemos una variable de tipo POSIX llamada FECHA, HORA en hms, Altura es numérica, Combinacion_Canya también lo es y Temperatura también.

```
head(dfp1)
```

```
## # A tibble: 6 x 5
##   FECHA               HORA     Altura Combinacion_Canya Temperatura
##   <dttm>              <time>    <dbl>             <dbl>       <dbl>
## 1 2015-12-11 00:00:00 12:47:02   138.                 2        14.6
## 2 2015-12-11 00:00:00 12:47:02   138.                 2        14.6
## 3 2015-12-11 00:00:00 12:47:02   138.                 2        14.6
## 4 2015-12-11 00:00:00 12:47:03   138.                 2        14.6
## 5 2015-12-11 00:00:00 12:47:03   138.                 2        14.6
## 6 2015-12-11 00:00:00 12:47:03   138.                 2        14.6
```

```
tail(dfp1)
```

```
## # A tibble: 6 x 5
##   FECHA               HORA     Altura Combinacion_Canya Temperatura
##   <dttm>              <time>    <dbl>             <dbl>       <dbl>
## 1 2015-12-11 00:00:00 13:49:41   949.                 2        14.7
## 2 2015-12-11 00:00:00 13:49:41   949.                 2        14.7
## 3 2015-12-11 00:00:00 13:49:41   949.                 2        14.7
## 4 2015-12-11 00:00:00 13:49:41   949.                 2        14.7
## 5 2015-12-11 00:00:00 13:49:41   949.                 2        14.7
## 6 2015-12-11 00:00:00 13:49:42   949.                 2        14.7
```

Con head y tail comprobamos que las instancias contienen las variables que habíamos obtenido antes.

```
summary(dfp1$FECHA)
```

```
##         Min.      1st Qu.       Median         Mean      3rd Qu.         Max.
## "2015-12-11" "2015-12-11" "2015-12-11" "2015-12-11" "2015-12-11" "2015-12-11"
```

Vemos que todas las instancias de fechas son la misma, ya que los cuartiles, mediana, máximo y mínimo son idénticos. Esto nos muestra que todas las instancias están tomadas el mismo día, ya que lo único que cambia es la hora.

```
summary(dfp1$Altura)
```

```
##    Min. 1st Qu.  Median    Mean 3rd Qu.    Max.
##   137.8   400.9   953.1   785.8  1079.0  1089.1
```

A partir de Altura vemos que la distribución es amplia, ya que va desde un mínimo de 137.8 hasta un máximo de 1089.1, con una media más sesgada hacia el máximo: 785.8

```
summary(dfp1$Combinacion_Canya)
```

```
##    Min. 1st Qu.  Median    Mean 3rd Qu.    Max.
##       1       1       2       2       3       3
```

Combinacion_Canya nos muestra que los únicos valores disponibles son 1, 2, 3.

```
summary(dfp1$Temperatura)
```

```
##    Min. 1st Qu.  Median    Mean 3rd Qu.    Max.
##   14.40   14.50   14.60   14.57   14.60   14.70
```

Las temperaturas por su parte se distribuyen desde 14.4 hasta 14.7.

3. Fichero Transactions from a Bakery

3.1. Importación del fichero

```
library(readr)
bak.sales <- read_csv("data/bakery_sales_revised.csv")
```

```
## Rows: 20507 Columns: 5
## -- Column specification --------------------------------------------------------
## Delimiter: ","
## chr (4): Item, date_time, period_day, weekday_weekend
## dbl (1): Transaction
##
## i Use `spec()` to retrieve the full column specification for this data.
## i Specify the column types or set `show_col_types = FALSE` to quiet this message.
```

```
save(bak.sales, file = 'data/results/bak.sales.RData')
```

3.2. Inspección de los datos

```
str(bak.sales)
```

```
## spc_tbl_ [20,507 x 5] (S3: spec_tbl_df/tbl_df/tbl/data.frame)
##  $ Transaction    : num [1:20507] 1 2 2 3 3 3 4 5 5 5 ...
##  $ Item           : chr [1:20507] "Bread" "Scandinavian" "Scandinavian" "Hot chocolate" ...
##  $ date_time      : chr [1:20507] "10/30/2016 9:58" "10/30/2016 10:05" "10/30/2016 10:05" "10/30/2016
##  $ period_day     : chr [1:20507] "morning" "morning" "morning" "morning" ...
##  $ weekday_weekend: chr [1:20507] "weekend" "weekend" "weekend" "weekend" ...
##  - attr(*, "spec")=
##   .. cols(
##   ..   Transaction = col_double(),
##   ..   Item = col_character(),
##   ..   date_time = col_character(),
##   ..   period_day = col_character(),
##   ..   weekday_weekend = col_character()
##   .. )
##  - attr(*, "problems")=<pointer: 0x0000021ab16fedb0>
```

La variable Transaction es numérica y parece indicar el cliente o la compra en la que se ha realizado cada importe, item es un string con el nombre del producto, date_time es la fecha y la hora en string, period_day es un string que marca el periodo de la jornada y weekday_weekend es un string que indica si se trata de un día entre semana o de fin de semana.

```r
head(bak.sales)
```

```
## # A tibble: 6 x 5
##   Transaction Item          date_time        period_day weekday_weekend
##         <dbl> <chr>         <chr>            <chr>      <chr>
## 1           1 Bread         10/30/2016 9:58  morning    weekend
## 2           2 Scandinavian  10/30/2016 10:05 morning    weekend
## 3           2 Scandinavian  10/30/2016 10:05 morning    weekend
## 4           3 Hot chocolate 10/30/2016 10:07 morning    weekend
## 5           3 Jam           10/30/2016 10:07 morning    weekend
## 6           3 Cookies       10/30/2016 10:07 morning    weekend
```

```r
tail(bak.sales)
```

```
## # A tibble: 6 x 5
##   Transaction Item         date_time      period_day weekday_weekend
##         <dbl> <chr>        <chr>          <chr>      <chr>
## 1        9682 Tacos-Fajita 4/9/2017 14:32 afternoon  weekend
## 2        9682 Coffee       4/9/2017 14:32 afternoon  weekend
## 3        9682 Tea          4/9/2017 14:32 afternoon  weekend
## 4        9683 Coffee       4/9/2017 14:57 afternoon  weekend
## 5        9683 Pastry       4/9/2017 14:57 afternoon  weekend
## 6        9684 Smoothies    4/9/2017 15:04 afternoon  weekend
```

Comprobamos con head y tail que las instancias tienen la variables esperadas.

```r
summary(bak.sales)
```

```
##   Transaction          Item           date_time         period_day
##  Min.   :   1   Length   :20507   Length   :20507   Length   :20507
##  1st Qu.:2552   N.unique :   94   N.unique : 9182   N.unique :    4
##  Median :5137   N.blank  :    0   N.blank  :    0   N.blank  :    0
##  Mean   :4976   Min.nchar:    3   Min.nchar:   13   Min.nchar:    5
##  3rd Qu.:7357   Max.nchar:   29   Max.nchar:   16   Max.nchar:    9
##  Max.   :9684
##   weekday_weekend
##  Length   :20507
##  N.unique :    2
##  N.blank  :    0
##  Min.nchar:    7
##  Max.nchar:    7
##
```

```r
unique(bak.sales$period_day)
```

```
## [1] "morning"   "afternoon" "evening"   "night"
```

```r
unique(bak.sales$weekday_weekend)
```

```
## [1] "weekend" "weekday"
```

A partir del summary vemos que Transaction tiene 9684 transacciones en total, Item tiene 94 productos unique en total (aunque se repiten 20507 veces a medida que son comprados varios clientes), date_time tiene también 20507 instancias repartidas en 9182 días (se hacen varias compras en un día), period_day tiene solo 4 posibilidades: morning, afternoon, evening, night y weekday_weekend contiene solo 2: weekend y weekday.

4. Fichero SPSS PsychBike.sav

4.1. Importación del fichero

```
library(haven)
ps.bike <- read_sav('data/PsychBike.sav')
save(ps.bike, file = 'data/results/ps.bike.RData')
```

4.2. Inspección de los datos

```
str(ps.bike)
```

```
## tibble [2,355 x 6] (S3: tbl_df/tbl/data.frame)
##  $ vehicle           : dbl+lbl [1:2355] 1, 5, 2, 1, 4, 1, 2, 1, 4, 7, 2, 3, 1, 1, 1, 2, 1, 2,...
##    ..@ format.spss: chr "F11.0"
##    ..@ labels     : Named num [1:7] 1 2 3 4 5 6 7
##    .. ..- attr(*, "names")= chr [1:7] "car" "LGV" "SUV" "bus" ...
##  $ Colour            : dbl+lbl [1:2355]  1,  2,  1, 99,  9,  3,  4,  2,  2, 99,  4,  4,  1,  ...
##    ..@ format.spss: chr "F11.0"
##    ..@ labels     : Named num [1:8] 1 2 3 4 5 6 9 99
##    .. ..- attr(*, "names")= chr [1:8] "blue" "red" "silver/grey" "white" ...
##  $ hour              : 'hms' num [1:2355] 16:00:00 16:00:00 16:00:00 16:00:00 ...
##   ..- attr(*, "units")= chr "secs"
##   ..- attr(*, "format.spss")= chr "TIME11.2"
##  $ helmet            : num [1:2355] 0 0 0 0 0 0 1 1 1 1 ...
##   ..- attr(*, "format.spss")= chr "F11.0"
##  $ Distance_from_kerb: num [1:2355] 0.5 0.5 0.5 0.5 0.5 0.5 1 1 1 1 ...
##   ..- attr(*, "label")= chr "Distance from kerb"
##   ..- attr(*, "format.spss")= chr "F11.1"
##  $ Passing_distance  : num [1:2355] 1.864 0.748 1.567 1.39 1.294 ...
##   ..- attr(*, "label")= chr "Passing distance"
##   ..- attr(*, "format.spss")= chr "F11.3"
```

```
head(ps.bike)
```

```
## # A tibble: 6 x 6
##   vehicle   Colour          hour   helmet Distance_from_kerb Passing_distance
##   <dbl+lbl> <dbl+lbl>       <time>  <dbl>              <dbl>            <dbl>
## 1 1 [car]    1 [blue]       16:00       0                0.5            1.86
## 2 5 [HGV]    2 [red]        16:00       0                0.5            0.748
## 3 2 [LGV]    1 [blue]       16:00       0                0.5            1.57
## 4 1 [car]   99 [unknown]    16:00       0                0.5            1.39
## 5 4 [bus]    9 [other]      16:00       0                0.5            1.29
## 6 1 [car]    3 [silver/grey] 16:00      0                0.5            1.26
```

```
tail(ps.bike)
```

```
## # A tibble: 6 x 6
##   vehicle   Colour          hour   helmet Distance_from_kerb Passing_distance
##   <dbl+lbl> <dbl+lbl>       <time>  <dbl>               <dbl>            <dbl>
## 1 2 [LGV]   9 [other]       10:00       1                1.25             1.10
## 2 1 [car]   3 [silver/grey] 10:00       1                1.25             1.01
## 3 1 [car]   2 [red]         10:00       1                1.25             0.922
## 4 5 [HGV]   4 [white]       10:00       1                1.25             0.564
## 5 1 [car]   1 [blue]        10:00       1                1.25             0.65
## 6 1 [car]   6 [green]       10:00       1                1.25             0.781
```

```
# summary(ps.bike) no funciona porque no se puede aplicar al tipo hms
```

5. Fichero data iris.zip

5.1. Descomprimir el fichero

```
unzip('data/iris.zip')
```

6. Fichero data iris.data

6.1. Importación del fichero

```
library(readr)
iris.df <- read_csv("data/iris/iris.data", col_names = FALSE)
```

```
## Rows: 150 Columns: 5
## -- Column specification --------------------------------------------------------
## Delimiter: ","
## chr (1): X5
## dbl (4): X1, X2, X3, X4
##
## i Use `spec()` to retrieve the full column specification for this data.
## i Specify the column types or set `show_col_types = FALSE` to quiet this message.
```

```
colnames(iris.df) <- c('sepal length', 'sepal width', 'petal length', 'petal width', 'class')
```

```
save(iris.df, file = 'data/results/irisdf.RData')
```

6.2. Inspección de los datos

```
str(iris.df)
```

```
## spc_tbl_ [150 x 5] (S3: spec_tbl_df/tbl_df/tbl/data.frame)
##  $ sepal length: num [1:150] 5.1 4.9 4.7 4.6 5 5.4 4.6 5 4.4 4.9 ...
##  $ sepal width : num [1:150] 3.5 3 3.2 3.1 3.6 3.9 3.4 3.4 2.9 3.1 ...
##  $ petal length: num [1:150] 1.4 1.4 1.3 1.5 1.4 1.7 1.4 1.5 1.4 1.5 ...
##  $ petal width : num [1:150] 0.2 0.2 0.2 0.2 0.2 0.4 0.3 0.2 0.2 0.1 ...
##  $ class       : chr [1:150] "Iris-setosa" "Iris-setosa" "Iris-setosa" "Iris-setosa" ...
##  - attr(*, "spec")=
##   .. cols(
##   ..   X1 = col_double(),
##   ..   X2 = col_double(),
##   ..   X3 = col_double(),
##   ..   X4 = col_double(),
##   ..   X5 = col_character()
##   .. )
##  - attr(*, "problems")=<pointer: 0x0000021ab16ff290>
```

Las cuatro primeras variables son numéricas, ya que contienen longitudes, mientras que la última es un string, ya que son los nombres del tipo de flor.

```
head(iris.df)
```

```
## # A tibble: 6 x 5
##   `sepal length` `sepal width` `petal length` `petal width` class
##            <dbl>         <dbl>          <dbl>         <dbl> <chr>
## 1            5.1           3.5            1.4           0.2 Iris-setosa
## 2            4.9           3              1.4           0.2 Iris-setosa
## 3            4.7           3.2            1.3           0.2 Iris-setosa
## 4            4.6           3.1            1.5           0.2 Iris-setosa
## 5            5             3.6            1.4           0.2 Iris-setosa
## 6            5.4           3.9            1.7           0.4 Iris-setosa
```

```
tail(iris.df)
```

```
## # A tibble: 6 x 5
##   `sepal length` `sepal width` `petal length` `petal width` class
##            <dbl>         <dbl>          <dbl>         <dbl> <chr>
## 1            6.7           3.3            5.7           2.5 Iris-virginica
## 2            6.7           3              5.2           2.3 Iris-virginica
## 3            6.3           2.5            5             1.9 Iris-virginica
## 4            6.5           3              5.2           2   Iris-virginica
## 5            6.2           3.4            5.4           2.3 Iris-virginica
## 6            5.9           3              5.1           1.8 Iris-virginica
```

```
summary(iris.df)
```

```
##   sepal length    sepal width     petal length    petal width
##  Min.   :4.300   Min.   :2.000   Min.   :1.000   Min.   :0.100
##  1st Qu.:5.100   1st Qu.:2.800   1st Qu.:1.600   1st Qu.:0.300
##  Median :5.800   Median :3.000   Median :4.350   Median :1.300
##  Mean   :5.843   Mean   :3.054   Mean   :3.759   Mean   :1.199
##  3rd Qu.:6.400   3rd Qu.:3.300   3rd Qu.:5.100   3rd Qu.:1.800
##  Max.   :7.900   Max.   :4.400   Max.   :6.900   Max.   :2.500
```

```
##        class
##  Length   :150
##  N.unique :  3
##  N.blank  :  0
##  Min.nchar: 11
##  Max.nchar: 15
##
```

7. Fichero JSON

7.2. Importar el fichero

```
library(jsonlite)
codif <- read_json('data/FileCodificado.json', simplifyVector = TRUE)
```

```
save(codif, file='data/results/codif.RData')
```

7.3. Inspección de los datos

```
str(codif)
```

```
## 'data.frame':    83 obs. of  22 variables:
##  $ Carburante             : int  1 1 1 1 1 1 1 1 1 1 ...
##  $ Potencia               : int  60 60 60 60 60 60 60 60 60 60 ...
##  $ Servicio_Vehiculo      : chr  "B00" "B00" "B00" "B00" ...
##  $ Actividad_Vehiculo     : chr  "D" "D" "D" "D" ...
##  $ GAMA                   : chr  "UTILITARIO" "UTILITARIO" "UTILITARIO" "UTILITARIO" ...
##  $ Unidades_Matriculadas  : int  0 0 0 0 0 0 0 0 0 0 ...
##  $ Localidad_definitiva   : chr  "ALGECIRAS" "ALGECIRAS" "ALGECIRAS" "ALGECIRAS" ...
##  $ Provincia_definitiva   : chr  "CADIZ" "CADIZ" "CADIZ" "CADIZ" ...
##  $ Codigo_Postal          : num  0.0297 0.0297 0.0297 0.0297 0.0297 0.0297 0.0297 0.0297 0.0297 0.029
##  $ Viviendas              : num  0.12 0.12 0.12 0.12 0.12 ...
##  $ precio_medio_m2        : num  0.18 0.18 0.18 0.18 0.18 ...
##  $ Peso_vivienda          : int  2 2 2 2 2 2 2 2 2 2 ...
##  $ RAISON_SOCIAL          : chr  "ALGECIREÑA DE MOTOR E INV., S.L." "ALGECIREÑA DE MOTOR E INV., S.L
##  $ RUE_SSOC               : chr  "Ctra. a Malaga, Km. 108" "Ctra. a Malaga, Km. 108" "Ctra. a Malaga
##  $ Edad_Conductor         : chr  "18 a 20 años" "21 a 24 años" "25 a 29 años" "30 a 34 años" ...
##  $ Numero de Conductores  : num  0.0132 0.0569 0.1086 0.1392 0.1706 ...
##  $ Antigüedad             : int  0 0 0 0 0 0 0 0 0 0 ...
##  $ Anos_Antiguedad        : int  0 0 0 0 0 0 0 0 0 0 ...
##  $ Numero_vehiculos_parque: int  0 0 0 0 0 0 0 0 0 0 ...
##  $ Cluster_GamaPotencia   : chr  "cluster_1_GamaPotencia" "cluster_1_GamaPotencia" "cluster_1_GamaPo
##  $ Cluster_Antiguedad     : chr  "cluster_1_Antiguedad" "cluster_1_Antiguedad" "cluster_1_Antiguedad
##  $ Cluster_Edad           : chr  "cluster_3_Edad" "cluster_3_Edad" "cluster_3_Edad" "cluster_3_Edad"
```

```
head(codif)
```

```
##   Carburante Potencia Servicio_Vehiculo Actividad_Vehiculo       GAMA
```

```
## 1          1       60               B00                  D UTILITARIO
## 2          1       60               B00                  D UTILITARIO
## 3          1       60               B00                  D UTILITARIO
## 4          1       60               B00                  D UTILITARIO
## 5          1       60               B00                  D UTILITARIO
## 6          1       60               B00                  D UTILITARIO
##   Unidades_Matriculadas Localidad_definitiva Provincia_definitiva Codigo_Postal
## 1                     0           ALGECIRAS                CADIZ        0.0297
## 2                     0           ALGECIRAS                CADIZ        0.0297
## 3                     0           ALGECIRAS                CADIZ        0.0297
## 4                     0           ALGECIRAS                CADIZ        0.0297
## 5                     0           ALGECIRAS                CADIZ        0.0297
## 6                     0           ALGECIRAS                CADIZ        0.0297
##   Viviendas precio_medio_m2 Peso_vivienda                  RAISON_SOCIAL
## 1    0.1201          0.1799             2 ALGECIREÑA DE MOTOR E INV., S.L.
## 2    0.1201          0.1799             2 ALGECIREÑA DE MOTOR E INV., S.L.
## 3    0.1201          0.1799             2 ALGECIREÑA DE MOTOR E INV., S.L.
## 4    0.1201          0.1799             2 ALGECIREÑA DE MOTOR E INV., S.L.
## 5    0.1201          0.1799             2 ALGECIREÑA DE MOTOR E INV., S.L.
## 6    0.1201          0.1799             2 ALGECIREÑA DE MOTOR E INV., S.L.
##                 RUE_SSOC Edad_Conductor Numero de Conductores Antigüedad
## 1 Ctra. a Malaga, Km. 108   18 a 20 años                0.0132          0
## 2 Ctra. a Malaga, Km. 108   21 a 24 años                0.0569          0
## 3 Ctra. a Malaga, Km. 108   25 a 29 años                0.1086          0
## 4 Ctra. a Malaga, Km. 108   30 a 34 años                0.1392          0
## 5 Ctra. a Malaga, Km. 108   35 a 39 años                0.1706          0
## 6 Ctra. a Malaga, Km. 108   40 a 44 años                0.1577          0
##   Anos_Antiguedad Numero_vehiculos_parque   Cluster_GamaPotencia
## 1               0                       0 cluster_1_GamaPotencia
## 2               0                       0 cluster_1_GamaPotencia
## 3               0                       0 cluster_1_GamaPotencia
## 4               0                       0 cluster_1_GamaPotencia
## 5               0                       0 cluster_1_GamaPotencia
## 6               0                       0 cluster_1_GamaPotencia
##     Cluster_Antiguedad   Cluster_Edad
## 1 cluster_1_Antiguedad cluster_3_Edad
## 2 cluster_1_Antiguedad cluster_3_Edad
## 3 cluster_1_Antiguedad cluster_3_Edad
## 4 cluster_1_Antiguedad cluster_3_Edad
## 5 cluster_1_Antiguedad cluster_3_Edad
## 6 cluster_1_Antiguedad cluster_3_Edad
```

```
tail(codif)
```

```
##    Carburante Potencia Servicio_Vehiculo Actividad_Vehiculo       GAMA
## 78          1       60               B00                  D UTILITARIO
## 79          1       60               B00                  D UTILITARIO
## 80          1       60               B00                  D UTILITARIO
## 81          1       60               B00                  D UTILITARIO
## 82          1       60               B00                  D UTILITARIO
## 83          1       60               B00                  D UTILITARIO
##    Unidades_Matriculadas    Localidad_definitiva Provincia_definitiva
## 78                     0 CHICLANA DE LA FRONTERA                CADIZ
## 79                     0 CHICLANA DE LA FRONTERA                CADIZ
```

```
## 80                    0 CHICLANA DE LA FRONTERA                CADIZ
## 81                    0 CHICLANA DE LA FRONTERA                CADIZ
## 82                    0 CHICLANA DE LA FRONTERA                CADIZ
## 83                    0 CHICLANA DE LA FRONTERA                CADIZ
##    Codigo_Postal Viviendas precio_medio_m2 Peso_vivienda          RAISON_SOCIAL
## 78         0.028    0.1132          0.4255             3       RAMON HOYO, S.L.
## 79         0.028    0.1132          0.4255             3 TALLERES COLCHÓN, S.L.
## 80         0.028    0.1132          0.4255             3 TALLERES COLCHÓN, S.L.
## 81         0.028    0.1132          0.4255             3 TALLERES COLCHÓN, S.L.
## 82         0.028    0.1132          0.4255             3 TALLERES COLCHÓN, S.L.
## 83         0.028    0.1132          0.4255             3 TALLERES COLCHÓN, S.L.
##                    RUE_SSOC Edad_Conductor Numero de Conductores Antigüedad
## 78 AVDA. REYES CATOLICOS, 5 Más de 74 años                0.0098          0
## 79               Caraza, 33   18 a 20 años                0.0099          0
## 80               Caraza, 33   21 a 24 años                0.0321          0
## 81               Caraza, 33   25 a 29 años                0.0793          0
## 82               Caraza, 33   30 a 34 años                0.0946          0
## 83               Caraza, 33   35 a 39 años                0.1150          0
##    Anos_Antiguedad Numero_vehiculos_parque   Cluster_GamaPotencia
## 78               0                       0 cluster_1_GamaPotencia
## 79               0                       0 cluster_1_GamaPotencia
## 80               0                       0 cluster_1_GamaPotencia
## 81               0                       0 cluster_1_GamaPotencia
## 82               0                       0 cluster_1_GamaPotencia
## 83               0                       0 cluster_1_GamaPotencia
##      Cluster_Antiguedad   Cluster_Edad
## 78 cluster_6_Antiguedad cluster_3_Edad
## 79 cluster_1_Antiguedad cluster_3_Edad
## 80 cluster_1_Antiguedad cluster_3_Edad
## 81 cluster_1_Antiguedad cluster_3_Edad
## 82 cluster_1_Antiguedad cluster_3_Edad
## 83 cluster_1_Antiguedad cluster_3_Edad
```

```
summary(codif)
```

```
##    Carburante    Potencia  Servicio_Vehiculo Actividad_Vehiculo        GAMA
##  Min.   :1    Min.   :60   Length   :83      Length   :83       Length   :83
##  1st Qu.:1    1st Qu.:60   N.unique : 1      N.unique : 1       N.unique : 1
##  Median :1    Median :60   N.blank  : 0      N.blank  : 0       N.blank  : 0
##  Mean   :1    Mean   :60   Min.nchar: 3      Min.nchar: 1       Min.nchar:10
##  3rd Qu.:1    3rd Qu.:60   Max.nchar: 3      Max.nchar: 1       Max.nchar:10
##  Max.   :1    Max.   :60
##  Unidades_Matriculadas Localidad_definitiva Provincia_definitiva
##  Min.   :0             Length   :83         Length   :83
##  1st Qu.:0             N.unique : 3         N.unique : 2
##  Median :0             N.blank  : 0         N.blank  : 0
##  Mean   :0             Min.nchar: 9         Min.nchar: 5
##  3rd Qu.:0             Max.nchar:23         Max.nchar: 6
##  Max.   :0
##  Codigo_Postal      Viviendas      precio_medio_m2  Peso_vivienda
##  Min.   :0.0280   Min.   :0.1132   Min.   :0.1799   Min.   :2.000
##  1st Qu.:0.0280   1st Qu.:0.1132   1st Qu.:0.1799   1st Qu.:2.000
##  Median :0.0280   Median :0.1132   Median :0.4255   Median :3.000
##  Mean   :0.1003   Mean   :0.1487   Mean   :0.3761   Mean   :2.843
```

```
##  3rd Qu.:0.0297   3rd Qu.:0.1201   3rd Qu.:0.4255   3rd Qu.:3.000
##  Max.   :0.4860   Max.   :0.3258   Max.   :0.6015   Max.   :4.000
##    RAISON_SOCIAL      RUE_SSOC    Edad_Conductor Numero de Conductores
##  Length   :83    Length   :83   Length   :83     Min.   :0.00740
##  N.unique : 7    N.unique : 7   N.unique :13     1st Qu.:0.02720
##  N.blank  : 0    N.blank  : 0   N.blank  : 0     Median :0.06250
##  Min.nchar:14    Min.nchar:10   Min.nchar:12     Mean   :0.06731
##  Max.nchar:32    Max.nchar:35   Max.nchar:14     3rd Qu.:0.10035
##                                                  Max.   :0.17060
##    Antigüedad Anos_Antiguedad Numero_vehiculos_parque Cluster_GamaPotencia
##  Min.   :0    Min.   :0       Min.   :0               Length   :83
##  1st Qu.:0    1st Qu.:0       1st Qu.:0               N.unique : 1
##  Median :0    Median :0       Median :0               N.blank  : 0
##  Mean   :0    Mean   :0       Mean   :0               Min.nchar:22
##  3rd Qu.:0    3rd Qu.:0       3rd Qu.:0               Max.nchar:22
##  Max.   :0    Max.   :0       Max.   :0
##  Cluster_Antiguedad    Cluster_Edad
##  Length   :83       Length   :83
##  N.unique : 4       N.unique : 1
##  N.blank  : 0       N.blank  : 0
##  Min.nchar:20       Min.nchar:14
##  Max.nchar:20       Max.nchar:14
##
```

8. Fichero JSON iris_json.json

8.1. Importar el fichero iris_json.json

```
library(jsonlite)
irisjson <- read_json('data/iris_json.json', simplifyVector = TRUE)
irisjson2 <- fromJSON('data/iris_json.json', simplifyVector = TRUE)
```

```
save(irisjson, file = 'data/results/irisjson.RData')
```

8.2. Inspección de los datos

```
str(irisjson)
```

```
## 'data.frame':    150 obs. of  5 variables:
##  $ Sepal.Length: num  5.1 4.9 4.7 4.6 5 5.4 4.6 5 4.4 4.9 ...
##  $ Sepal.Width : num  3.5 3 3.2 3.1 3.6 3.9 3.4 3.4 2.9 3.1 ...
##  $ Petal.Length: num  1.4 1.4 1.3 1.5 1.4 1.7 1.4 1.5 1.4 1.5 ...
##  $ Petal.Width : num  0.2 0.2 0.2 0.2 0.2 0.4 0.3 0.2 0.2 0.1 ...
##  $ Species     : chr  "setosa" "setosa" "setosa" "setosa" ...
```

```
head(irisjson)
```

```
##   Sepal.Length Sepal.Width Petal.Length Petal.Width Species
```

```
## 1          5.1         3.5          1.4         0.2  setosa
## 2          4.9         3.0          1.4         0.2  setosa
## 3          4.7         3.2          1.3         0.2  setosa
## 4          4.6         3.1          1.5         0.2  setosa
## 5          5.0         3.6          1.4         0.2  setosa
## 6          5.4         3.9          1.7         0.4  setosa
```

```
tail(irisjson)
```

```
##     Sepal.Length Sepal.Width Petal.Length Petal.Width   Species
## 145          6.7         3.3          5.7         2.5 virginica
## 146          6.7         3.0          5.2         2.3 virginica
## 147          6.3         2.5          5.0         1.9 virginica
## 148          6.5         3.0          5.2         2.0 virginica
## 149          6.2         3.4          5.4         2.3 virginica
## 150          5.9         3.0          5.1         1.8 virginica
```

```
summary(irisjson)
```

```
##   Sepal.Length    Sepal.Width     Petal.Length    Petal.Width
##  Min.   :4.300   Min.   :2.000   Min.   :1.000   Min.   :0.100
##  1st Qu.:5.100   1st Qu.:2.800   1st Qu.:1.600   1st Qu.:0.300
##  Median :5.800   Median :3.000   Median :4.350   Median :1.300
##  Mean   :5.843   Mean   :3.057   Mean   :3.758   Mean   :1.199
##  3rd Qu.:6.400   3rd Qu.:3.300   3rd Qu.:5.100   3rd Qu.:1.800
##  Max.   :7.900   Max.   :4.400   Max.   :6.900   Max.   :2.500
##       Species
##  Length   :150
##  N.unique :  3
##  N.blank  :  0
##  Min.nchar:  6
##  Max.nchar: 10
##
```

8.3. Exportar datos en formato JSON

```
write_json(iris.df, path = 'data/results/irisdfjson.json')
newirisjson <- read_json('data/results/irisdfjson.json', simplifyVector = TRUE)
head(newirisjson)
```

```
##   sepal length sepal width petal length petal width       class
## 1          5.1         3.5          1.4         0.2 Iris-setosa
## 2          4.9         3.0          1.4         0.2 Iris-setosa
## 3          4.7         3.2          1.3         0.2 Iris-setosa
## 4          4.6         3.1          1.5         0.2 Iris-setosa
## 5          5.0         3.6          1.4         0.2 Iris-setosa
## 6          5.4         3.9          1.7         0.4 Iris-setosa
```

Se recupera bien el archivo.

```r
json.no.pretty <- toJSON(iris.df)
json.pretty <- toJSON(iris.df, pretty = TRUE)
```

El parámetro pretty va haciendo saltos de línea para que sea más visible.